

RAG系统介绍

什么是RAG

RAG (Retrieval-Augmented Generation) 是一种结合检索和生成的AI技术。它通过从知识库中检索相关信息，然后将这些信息作为上下文提供给大语言模型，从而生成更准确、更有依据的回答。

RAG的核心组件

RAG系统主要包含三个核心组件：文档处理模块负责加载和分块文档；检索模块使用向量数据库（如FAISS）进行语义搜索；生成模块使用大语言模型（如GPT、Qwen）基于检索到的上下文生成答案。

向量数据库的作用

向量数据库如FAISS用于存储文档的向量表示。通过将文本转换为高维向量，可以快速找到与查询语义相似的文档片段。FAISS支持多种索引类型，包括Flat（精确搜索）、IVF（倒排索引）和HNSW（层次图）。

混合检索策略

混合检索结合了语义检索和关键词检索的优势。语义检索使用Sentence-BERT等模型捕捉语义相似性，而BM25算法则擅长精确的关键词匹配。通过加权融合两种方法的结果，可以获得更好的检索效果。

提示工程的重要性

提示工程是RAG系统中的关键环节。通过精心设计的提示模板，可以引导大语言模型更好地理解上下文和问题，生成更准确的答案。常见的提示策略包括思维链（CoT）、少样本学习和自我反思。